

RAKAMIN FINAL TASK

CREDIT SCORE PREDICTIONS

WITH LOGISTIC REGRESSION AND

XGBOOST

ANGGA YULIAN ADI PRADANA

3 Januari 2025

LINK GITHUB: [HTTPS://GITHUB.COM/ANGGAPRADANAA/RAKAMIN_FINAL_TASK](https://github.com/ANGGAPRADANAA/RAKAMIN_FINAL_TASK)



KONTEKS MASALAH

Latar Belakang

- Home Credit ingin memaksimalkan potensi data untuk memprediksi skor kredit secara akurat.
- Tujuan: Memastikan pelanggan layak kredit tidak ditolak dan menyediakan struktur kredit yang mendukung keberhasilan pelunasan.
- Evaluasi dilakukan berdasarkan analisa mendalam dan akurasi pemodelan.



KONTEKS MASALAH

01

Goal

Meningkatkan akurasi prediksi risiko kredit untuk memastikan penyaluran kredit yang tepat.

02

Objective

- Menggali potensi maksimal data melalui Logistic Regression dan XGBoost.
- Menentukan klasifikasi default kredit.

03

Metrics

- ROC-AUC: Mengukur kemampuan model membedakan default / non-default.
- F1-Score: Menyeimbangkan presisi dan recall pada data tidak seimbang.
- Treshold Optimization: Menentukan keputusan kredit yang optimal.

EDA (Exploratory Data Analysis)

01

Jumlah Data:

- X: 121.
- Y: 1.

02

Distribusi Target:

- Proporsi kelas default vs non-default: 91,9% (non-default):8,1% (default).

03

Masalah Data:

- Missing value > 30%.
- Outlier pada fitur numerik.
- Distribusi target yang tidak seimbang.

Data Cleaning and Preprocessing

01

Data Cleaning:

- Menghapus kolom dengan missing values > 30%.
- Mengimputasi missing values berdasarkan median

02

Data Preprocessing:

- Numerik: Menangani outlier menggunakan metode IQR (Interquartile Range) dan normalisasi menggunakan RobustScaler untuk mengurangi efek outlier.
- Kategorikal: Mengubah beberapa kolom menjadi tipe category untuk optimasi memori dan encoding menggunakan Label Encoding untuk variabel kategorikal dengan LabelEncoder.
- Fitur tambahan dan transformasi: Konversi fitur berbasis waktu (DAYS_) menjadi years.
- Menggunakan SMOTEENN untuk menangani class imbalance.

Pemodelan

01

Logistic Regression:

- Model baseline untuk memahami hubungan linear antar variabel.

02

XGBoost:

- Gradient boosting untuk menangkap interaksi variabel kompleks.

03

Hyperparameter Tuning

- Logistic Regression: Optimasi C dan solver.
- XGBoost: Optimasi max_depth, scale_pos_weight, dan learning_rate.

Evaluasi Hasil Pemodelan

01

Tabel Perbandingan Model:

- Model baseline untuk memahami hubungan linear antar variabel.

Metrics	Logistic Regression	XGBoost
AUC-ROC	0.67	0.70
F1 Score	0.243	0.256
Accuracy	0.77	0.84

02

Threshold Optimization:

- Logistic Regression (optimal threshold: 0.5).
- XGBoost (optimal threshold: 0.7).

03

Confussion Matrix:

- Visualisasi confusion matrix untuk masing-masing model.

Insight dan Analisis

01

XGBoost unggul dalam performa

- ROC-AUC lebih tinggi, mampu menangkap kompleksitas data.

02

Logistic Regression sebagai baseline

- Memberikan interpretasi sederhana terhadap hubungan antar fitur.

03

Treshold Optimal

- Mengurangi false negatives, sehingga pelanggan layak tidak ditolak.

Rekomendasi Bisnis

01

Implementasi Model XGBoost

- Menggunakan threshold 0.7 untuk keputusan kredit.

02

Penyempurnaan Data

- Pengumpulan data eksternal untuk fitur tambahan (EXT_SOURCE).

03

Sosialisasi Kredit Tepat Sasaran

- Menggunakan skor prediktif untuk menawarkan pinjaman dengan struktur yang sesuai.

Penutup

01

Kesimpulan

- Logistic Regression memberikan baseline interpretasi.
- XGBoost memberikan performa terbaik untuk prediksi default.

02

Langkah Selanjutnya

- Validasi model pada dataset baru.
- Evaluasi dampak terhadap probabilitas perusahaan.